

Taller práctico — Regresión Logística

Diagnóstico de cáncer de mama a partir de datos clínicos

Contexto

Un laboratorio quiere apoyar el diagnóstico de tumores de mama usando mediciones obtenidas por biopsia. Cada fila del dataset corresponde a un tumor, caracterizado por 10 variables numéricas (tamaño, textura, forma, etc.), y una etiqueta que indica si fue diagnosticado como benigno o maligno.

Tu tarea es construir un modelo de regresión logística que apoye esta decisión clínica, y — más importante — justificar cómo se debe usar e interpretar ese modelo.

Dataset

Campo	Descripción
Archivo	cancer_mama.csv
Filas	569 pacientes
Columnas	10 variables numéricas (medidas morfológicas del tumor) + 1 columna objetivo
Variable objetivo	diagnosis → "maligno" o "benigno"
Variables predictoras	mean radius, mean texture, mean perimeter, mean area, mean smoothness, mean compactness, mean concavity, mean concave points, mean symmetry, mean fractal dimension
Fuente	Wisconsin Breast Cancer Diagnostic Dataset (mediciones de núcleos celulares de biopsias, vía scikit-learn)

Entregable

Un notebook (.ipynb) con código y celdas de markdown explicando cada decisión, más las conclusiones.

Tareas

1. Preparación

- Carga el dataset y revisa tipos de datos, nulos y balance de clases.
- Divide en train/test y escala las variables predictoras.

2. Modelamiento

- Entrena un LogisticRegression sobre el set de entrenamiento.
- Genera las predicciones sobre el set de prueba.

3. Evaluación crítica

- Calcula la matriz de confusión, precision, recall y F1-score
- Identifica: en este problema, ¿qué error es más costoso, un falso negativo o un falso positivo? Justifica.
- Con base en eso, decide si el umbral de decisión por defecto (0.5) es adecuado o si moverlo tendría sentido.

4. Interpretación

- Extrae los coeficientes del modelo (model.coef_) y señala las 3 variables con mayor peso.
- Explica, en términos clínicos simples, qué significa el signo de cada coeficiente para esas variables.

5. Conclusión

- ¿Usarías este modelo tal cual para apoyar decisiones médicas reales? ¿Qué le falta o qué riesgos tiene?

Rúbrica de evaluación

Criterio	Peso	Qué se evalúa
Preparación de datos	15%	Split train/test correcto, escalado justificado, sin fuga de información (data leakage).
Entrenamiento del modelo	15%	LogisticRegression bien configurada; código limpio y reproducible.
Evaluación	25%	Uso de matriz de confusión, precision, recall y F1 (no solo accuracy); interpretación en contexto clínico.
Interpretación de coeficientes	20%	Explica qué variables más influyen en el diagnóstico y en qué dirección (signo del coeficiente).
Decisión sobre el umbral	15%	Argumenta si conviene mover el umbral de 0.5 dado el costo de un falso negativo vs. un falso positivo.
Comunicación	10%	Informe corto, claro, con conclusiones accionables (no solo código).